

МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ

Учреждение образования

«Гродненский государственный университет имени Янки Купалы»

Факультет математики и информатики

Кафедра системного программирования и компьютерной безопасности

ЦЫБИН ЕГОР АЛЕКСЕЕВИЧ

**Анализ графа сетевого взаимодействия пользователей для выявления
лидеров мнений и изолированных групп методами выделения
сообществ и графовых нейронных сетей**

Курсовой проект по учебной дисциплине
«Машинное обучение и нейронные сети»
студента 3 курса специальности
6-05-0533-12 «Кибербезопасность»

Научный руководитель
Кадан Александр Михайлович,
заведующий кафедрой
системного программирования и компью-
терной безопасности,
кандидат технических наук, доцент

Гродно 2026

РЕФЕРАТ

Курсовой проект: 28 с., 3 рис., 7 табл., 19 источников.

АНАЛИЗ ГРАФОВ, ВЫДЕЛЕНИЕ СООБЩЕСТВ, СОЦИОМЕТРИЯ, МОДУЛЯРНОСТЬ, АЛГОРИТМ ЛУВЕНА, АЛГОРИТМ ЛЕЙДЕНА, ГРАФОВЫЕ НЕЙРОННЫЕ СЕТИ, GCN, GRAPHSAGE, ЛИДЕРЫ МНЕНИЙ, ЦЕНТРАЛЬНОСТЬ.

Объект исследования: графы сетевого взаимодействия пользователей в социальных сетях.

Предмет исследования: алгоритмы выделения сообществ, метрики центральности и графовые нейронные сети в задачах социометрии.

Цель работы: изучить методы анализа графа сетевого взаимодействия пользователей и эмпирически сравнить классические алгоритмы выделения сообществ и графовые нейронные сети в задаче выявления лидеров мнений и изолированных групп.

Методы исследования: теоретико-графовое моделирование, статистический анализ, эмпирический бенчмарк, машинное обучение на графах.

Исследования и разработки: исторический обзор от социограмм Морено [1] до современных GNN; формализация задачи разбиения графа; описание алгоритмов Louvain [9], Leiden [17], Label Propagation [8], Girvan-Newman [6], Walktrap [10] и сетей GCN [15] и GraphSAGE [16]; реализация модуля бенчмарка с метриками NMI, AMI, ARI, модулярности и точности; обучение GNN с разделением вершин на обучающую, валидационную и тестовую выборки и чекпоинтами; эмпирическое сравнение на Karate, Dolphins, Football, email-Eu-core, ego-Facebook и DBLP [19].

Элементы научной новизны: систематизация классических и нейросетевых методов выделения сообществ в едином интерфейсе $f: G \rightarrow \mathbb{Z}^n$; воспроизводимое сравнение восьми алгоритмов и двух GNN-архитектур на шести датасетах.

Область возможного практического применения: анализ социальных сетей, выявление сообществ и лидеров мнений, обнаружение слабосвязанных групп, рекомендательные системы.

Автор работы подтверждает, что приведённый в курсовом проекте расчётно-аналитический материал правильно и объективно отражает состояние иссле-

дуемого процесса, а все заимствованные из литературных и других источников теоретические, методологические и методические положения и концепции сопровождаются ссылками на их авторов.

SUMMARY

Course project: 28 pp, 3 fig, 7 tbl, 19 ref.

GRAPH ANALYSIS, COMMUNITY DETECTION, SOCIOMETRY, MODULARITY, LOUVAIN ALGORITHM, LEIDEN ALGORITHM, GRAPH NEURAL NETWORKS, GCN, GraphSAGE, OPINION LEADERS, CENTRALITY.

The object of the research: graphs of user communication in social networks.

The subject of the research: community detection algorithms, centrality measures and graph neural networks applied to sociometric tasks.

The research objective: to study methods of social graph analysis and empirically compare classical community detection algorithms with graph neural networks for the task of opinion-leader and isolated-group identification.

Research methods: graph-theoretic modelling, statistical analysis, empirical benchmarking, machine learning on graphs.

Research and developments: a historical review from Moreno's sociograms to modern GNNs; a formal description of graph partitioning; specification of Louvain, Leiden, Label Propagation, Girvan-Newman, Walktrap and GCN/GraphSAGE; a benchmark harness with NMI, AMI, ARI, modularity and best-permutation accuracy; GNN training with обучающая/валидационная/тестовая выборки split and model checkpointing; empirical comparison on Karate, Dolphins, Football, email-Eu-core, ego-Facebook and DBLP.

Elements of scientific novelty: unification of classical and neural community detection methods under a single interface $f: G \rightarrow \mathbb{Z}^n$; reproducible comparison of eight algorithms and two GNN architectures on six datasets.

The field of possible practical use: social network analysis, community and opinion-leader detection, weakly-connected group identification, recommender systems.

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	6
1 Актуальность темы, исторический обзор и обзор литературы	8
1.1 Актуальность задачи социометрии в условиях цифровых социальных сетей	8
1.2 Историческая справка	8
1.3 Обзор литературы и сравнение подходов	9
2 Математическая модель социального графа и методов его анализа	11
2.1 Граф и его матричные представления	11
2.2 Модели случайных графов и модулярность	11
2.3 Классические алгоритмы выделения сообществ	12
2.4 Метрики качества кластеризации	16
2.5 Метрики центральности	18
2.6 Графовые нейронные сети	18
3 Практический материал	20
3.1 Программная реализация и используемые датасеты	20
3.2 Структурный анализ графов	20
3.3 Бенчмарк классических алгоритмов выделения сообществ . .	21
3.4 Обучение графовых нейронных сетей	22
3.5 Выявление лидеров мнений	23
3.6 Выявление изолированных групп	24
ЗАКЛЮЧЕНИЕ	26
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	27

ВВЕДЕНИЕ

Актуальность темы. Современная коммуникация всё чаще опосредуется цифровыми социальными сетями: пользователи обмениваются сообщениями, образуют сообщества, формируют общественное мнение через лидеров и оказываются в изолированных группах. Объёмы накапливаемых данных таковы, что ручной социометрический анализ невозможен, а традиционные опросные методы не масштабируются. Задача автоматического выявления лидеров мнений и изолированных групп критична для рекомендательных систем, маркетинга, обнаружения координированной активности и понимания политической поляризации. При этом методы анализа графов прошли существенную эволюцию- от качественных социограмм Морено [1] до современных графовых нейронных сетей [15, 16]- и выбор между ними на практике далеко не очевиден.

Практическая значимость работы состоит в построении воспроизводимого модуля сравнения восьми классических алгоритмов выделения сообществ и двух графовых нейросетевых архитектур на эталонных и реальных датасетах. Полученные результаты позволяют обоснованно выбирать алгоритм в зависимости от размера графа, числа сообществ и наличия частичной разметки.

Степень изученности. Задача выделения сообществ изучается с 1970-х годов: классический датасет Захари [3], модулярность Ньюмана [6], алгоритмы Louvain [9] и Leiden [17], методы случайных блужданий Walktrap [10]. Современный этап представлен графовыми нейронными сетями GCN [15] и GraphSAGE [16], развиваемыми компаниями Google, Meta, Stanford SNAP [19] и др.

Объект исследования- графы сетевого взаимодействия пользователей в социальных сетях.

Предмет исследования- алгоритмы выделения сообществ, метрики центральности и графовые нейронные сети в задачах социометрии.

Цель работы- изучить методы анализа графа сетевого взаимодействия пользователей и эмпирически сравнить классические алгоритмы выделения сообществ и графовые нейронные сети в задаче выявления лидеров мнений и изолированных групп.

Задачи работы:

1. Изучить актуальность темы, проследить историю развития методов и проанализировать литературу.
2. Дать строгое математическое описание моделей графа, алгоритмов выделения сообществ, метрик центральности и нейросетевых архитектур GCN и GraphSAGE.
3. Провести эмпирическое сравнение методов на шести датасетах, проинтерпретировать полученные результаты.

Методы исследования: теоретико-графовое моделирование, статистический анализ структурных характеристик графа, эмпирический бенчмарк алгоритмов, обучение графовых нейронных сетей.

Структура работы. Работа состоит из введения, трёх глав, заключения и списка использованных источников. Первая глава посвящена актуальности темы, истории вопроса и обзору литературы; вторая- теоретическому материалу; третья- практической реализации и эмпирическим результатам.

1 АКТУАЛЬНОСТЬ ТЕМЫ, ИСТОРИЧЕСКИЙ ОБЗОР И ОБЗОР ЛИТЕРАТУРЫ

1.1 Актуальность задачи социометрии в условиях цифровых социальных сетей

Социометрия как область знания зарождается в 1930-х годах в работах Я. Морено [1], предложившего изображать межличностные отношения в виде графа. С появлением цифровых социальных сетей (Facebook, ВКонтакте, Twitter, Telegram) объём социометрических данных вырос на много порядков: типичная социальная сеть содержит миллионы вершин и миллиарды рёбер. Это сделало невозможным ручной анализ и потребовало автоматических алгоритмических методов.

Задача *выявления лидеров мнений* имеет прямое практическое значение: лидеры- это узлы, чьё мнение быстрее всего распространяется по сети, поэтому маркетинг и информационные кампании ориентируются именно на них. Задача *выявления изолированных групп*- обнаружение слабосвязанных подсообществ- важна для рекомендательных систем (изолированные пользователи получают плохие рекомендации), а также для обнаружения координированной дезинформации (изолированные «эхо-камеры»).

Графовое представление позволяет свести обе задачи к строгим математическим конструкциям. Пусть $G = (V, E)$ - неориентированный граф взаимодействий, $|V| = n$, $|E| = m$. Тогда:

- лидеры мнений- узлы с наибольшими значениями метрик центральности (степенной, betweenness, closeness, eigenvector, PageRank);
- изолированные группы- подмножества $S \subseteq V$ с малым conductance $\varphi(S) = |\partial S| / \min(\text{vol}(S), \text{vol}(V \setminus S))$.

1.2 Историческая справка

Идея графового представления социальных связей восходит к работе Я. Морено «Who Shall Survive?» [1]. Морено ввёл понятие *социограммы* и стал применять её для анализа малых групп. Однако вплоть до 1950-х годов аппарат оставался качественным: социограммы рисовались вручную, формальных метрик не было.

Принципиальный сдвиг произошёл с публикацией П. Эрдёшем и А. Реньи серии работ о случайных графах [2]. Модель $G(n, p)$ впервые позволила говорить о структуре графа в строгих вероятностных терминах. В 1977 году В. Захари [3] опубликовал ставший каноническим датасет карате-клуба- 34 члена и 78 рёбер с известным историческим расколом, до сих пор используемый как первый бенчмарк новых алгоритмов.

На рубеже 1990-2000-х Д. Уоттс и С. Строгатц [4] и А. Барабаши и Р. Альберт [5] показали, что реальные сети одновременно демонстрируют высокую кластеризацию, малую среднюю длину пути и степенное распределение степеней. Это привело к появлению моделей малого мира (WS) и сетей с предпочтительным присоединением (BA).

Современная эпоха алгоритмического выделения сообществ начинается с работы М. Гирвана и М. Ньюмана [6], в которой была введена *модулярность*. Прямая оптимизация модулярности оказалась NP-трудной [11], поэтому В. Блондель и соавторы [9] предложили жадный алгоритм Louvain. В 2007 году С. Фортунато и М. Бартелеми [7] показали фундаментальное ограничение модулярности- *предел разрешения*. В 2019 году В. Трааг и соавторы [17] устранили недостаток Louvain (несвязные сообщества), предложив алгоритм Leiden.

Параллельно развивались алгоритмы случайных блужданий: Walktrap [10]; и быстрые эвристики: Label Propagation [8].

С 2017 года наступает эпоха графовых нейронных сетей. Т. Кипф и М. Веллинг [15] предложили GCN на основе аппроксимации Чебышёва спектральной свёртки [14]. В том же году В. Хэмилтон и соавторы [16] представили GraphSAGE с раздельным обучением представления узла и его соседей.

1.3 Обзор литературы и сравнение подходов

Анализ литературы показывает, что в настоящее время сосуществуют три основных семейства методов выделения сообществ.

Алгоритмы оптимизации модулярности (Louvain [9], Leiden [17], Fast Greedy)- наиболее распространённые в практике. Их преимущества: высокая скорость, отсутствие необходимости в разметке, понятная интерпретация. Недостаток- предел разрешения [7]: невозможность обнаруживать сообщества размера менее $\sqrt{2m}$.

Алгоритмы на случайных блужданиях (Walktrap [10]) - основаны на наблюдении, что блуждания «застревают» в плотных сообществах.

Графовые нейронные сети (GCN [15], GraphSAGE [16]) - обучаемые модели, использующие частичную разметку и матрицу признаков. Они превосходят классические методы при наличии разметки, но требуют размеченных данных, GPU-ресурсов и подвержены переобучению. Современные обзоры [12, 13] рассматривают эти три семейства как взаимодополняющие.

Стандартными датасетами для сравнения остаются Karate [3], Dolphins, Football [6] и большие графы из репозитория Stanford SNAP [19]. Стандартными метриками качества - NMI, AMI, ARI и модулярность.

2 МАТЕМАТИЧЕСКАЯ МОДЕЛЬ СОЦИАЛЬНОГО ГРАФА И МЕТОДОВ ЕГО АНАЛИЗА

2.1 Граф и его матричные представления

Определение 2.1. Неориентированным графом называется упорядоченная пара $G = (V, E)$, где V - конечное непустое множество вершин, а $E \subseteq \{\{u, v\} : u, v \in V, u \neq v\}$ - множество рёбер.

Определение 2.2. Матрицей смежности графа G , $|V| = n$, называется симметричная матрица $A \in \{0, 1\}^{n \times n}$ с

$$A_{ij} = \begin{cases} 1, & \{v_i, v_j\} \in E, \\ 0, & \text{иначе.} \end{cases} \quad (1)$$

Определение 2.3. Степенью вершины v называется $\deg(v) = \sum_j A_{vj}$. Степенной матрицей называется $D = \text{diag}(\deg(v_1), \dots, \deg(v_n))$.

Определение 2.4. Лапласианом графа называется $L = D - A$. Нормализованным лапласианом- матрица

$$L_{\text{sym}} = D^{-1/2} L D^{-1/2} = I - D^{-1/2} A D^{-1/2}. \quad (2)$$

Теорема 2.1. Матрица L симметрична и положительно полуопределена. Все её собственные значения неотрицательны: $0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$. Кратность нулевого собственного значения равна числу связных компонент графа [12].

2.2 Модели случайных графов и модулярность

Определение 2.5 ($G(n, p)$, [2]). Случайным графом Эрдёша-Реньи называется граф на n вершинах, в котором каждое из C_n^2 рёбер включается независимо с вероятностью p . Ожидаемое число рёбер: $\mathbb{E}|E| = p \cdot n(n - 1)/2$.

Определение 2.6 ($\text{BA}(n, m)$, [5]). Модель Барабаши-Альберт строит граф последовательным добавлением узлов; каждый новый узел соединяется с m существующими с вероятностью, пропорциональной их степени:

$$\Pr(v_t \sim u) = \frac{\deg(u)}{\sum_w \deg(w)}. \quad (3)$$

При $n \rightarrow \infty$ распределение степеней сходится к степенному $\Pr(\deg = k) \sim k^{-3}$.

Определение 2.7 ($WS(n, k, p)$, [4]). Граф малого мира строится из k -регулярной кольцевой решётки путём независимой перепосадки каждого ребра с вероятностью p .

Определение 2.8 (модулярность Ньюмана, [6]). Модулярностью разбиения σ называется

$$Q(\sigma) = \frac{1}{2m} \sum_{i,j} \left[A_{ij} - \frac{k_i k_j}{2m} \right] \delta(\sigma(i), \sigma(j)), \quad (4)$$

где $k_i = \deg(i)$, $m = |E|$, δ - символ Кронекера.

Значение $Q \in [-1/2, 1]$; $Q > 0.3$ считается признаком значимой модульной структуры. Прямая оптимизация Q NP-трудна [11].

Замечание 2.1 (предел разрешения, [7]). Оптимизация Q не способна обнаружить сообщества размера менее $\sqrt{2m}$.

2.3 Классические алгоритмы выделения сообществ

Прямая максимизация модулярности (определение 2.8) является NP-трудной задачей [11]: число возможных разбиений n вершин на непустые непересекающиеся подмножества (число Белла B_n) растёт быстрее экспоненциально, и перебор невозможен уже при $n \approx 30$. Поэтому все практические алгоритмы- эвристические; они отличаются тем, какую структуру поиска используют и какой функционал оптимизируют. Ниже описаны шесть наиболее распространённых методов.

2.3.1 Алгоритм Лувена [9]. Жадный многоуровневый метод. Идея: вместо поиска глобального оптимума модулярности находить локально оптимальные перемещения отдельных вершин, а затем повторять процедуру на сжатом графе. Алгоритм состоит из двух фаз, которые рекурсивно повторяются.

Фаза 1 (локальное перемещение). Изначально каждой вершине $v \in V$ присваивается собственное сообщество. Далее в произвольном порядке для каждой вершины рассматриваются все сообщества c её соседей; вершина переносится в то сообщество, которое даёт наибольший положительный при-

рост модулярности

$$\Delta Q(v \rightarrow c) = \frac{\Sigma_{\text{in}}^c + 2k_{v,c}}{2m} - \left(\frac{\Sigma_{\text{tot}}^c + k_v}{2m} \right)^2 - \left[\frac{\Sigma_{\text{in}}^c}{2m} - \left(\frac{\Sigma_{\text{tot}}^c}{2m} \right)^2 - \left(\frac{k_v}{2m} \right)^2 \right], \quad (5)$$

где Σ_{in}^c - сумма весов рёбер внутри сообщества c , Σ_{tot}^c - сумма степеней вершин c , $k_{v,c}$ - сумма весов рёбер от v к вершинам c . Если максимальный $\Delta Q \leq 0$, вершина остаётся на месте. Фаза 1 повторяется до тех пор, пока хотя бы одна вершина меняет сообщество.

Фаза 2 (агрегирование). Каждое сообщество, найденное на фазе 1, заменяется одной супер-вершиной; рёбра внутри сообщества становятся петлёй с весом, равным удвоенной внутренней сумме; рёбра между разными сообществами объединяются во взвешенные рёбра между супер-вершинами. На полученном уменьшенном графе снова запускается фаза 1, и так далее- пока модулярность продолжает расти.

Эмпирическая сложность алгоритма $O(n \log n)$; на графах с миллионами вершин Лувен сходится за минуты. Его главный недостаток- возможность образования несвязных сообществ (вершина может «утянуть» с собой группу, разорвав исходное сообщество), что было устранено в алгоритме Лейдена.

2.3.2 Алгоритм Лейдена [17]. Прямое улучшение алгоритма Лувена, гарантирующее связность найденных сообществ. Между фазами 1 и 2 вводится дополнительная *фаза уточнения*.

После фазы 1 для каждого найденного сообщества C его вершины снова помещаются каждая в своё под-сообщество; затем запускается ограниченное локальное перемещение, в котором вершины могут переходить только в под-сообщества, целиком содержащиеся в C . В результате каждое исходное сообщество C разбивается на одно или несколько связных компонент-сообществ. Авторами доказано [17], что все сообщества, найденные алгоритмом Лейдена, связны, и что при достаточном числе итераций алгоритм сходится к γ -плотному разбиению. По эмпирической сложности Лейден сопоставим с Лувеном.

2.3.3 Алгоритм распространения меток (Label Propagation) [8]. Сверхбыстрый алгоритм без целевого функционала. Идея: каждая вершина «голосует» меткой большинства своих соседей, и при многократном повторении такого голосования вершины одного плотного сообщества постепенно приходят к общей метке.

Изначально каждой вершине присваивается уникальная метка $\ell^{(0)}(v) = v$. На итерации t для каждой вершины v (в случайном порядке) вычисляется новая метка как наиболее частая среди меток её соседей на предыдущей итерации:

$$\ell^{(t)}(v) = \arg \max_{\ell} |\{u \in N(v) : \ell^{(t-1)}(u) = \ell\}|. \quad (6)$$

При нескольких максимумах метка выбирается случайно. Алгоритм сходится, когда ни одна метка не меняется; итоговые группы одинаковых меток образуют сообщества. Сложность $O(m)$ на итерацию, число итераций обычно невелико- метод реально работает за почти линейное время.

Основной недостаток- неустойчивость и тенденция к коллапсу. На плотных графах с большим числом классов одна-две начальные метки начинают доминировать и поглощают остальные, что в пределе приводит к разбиению на одну компоненту ($\hat{k} = 1$, $\text{NMI} = 0$). Это явление эмпирически наблюдается на датасете email-Eu-core (см. раздел 3.3).

2.3.4 Алгоритм Гирвана-Ньюмана [6]. Один из первых алгоритмов выделения сообществ, основанный на иерархическом удалении «мостов»- рёбер, лежащих на наибольшем числе кратчайших путей.

Определение 2.9 (промежуточность ребра). Промежуточностью ребра e называется

$$C_B(e) = \sum_{s \neq t} \frac{\sigma_{st}(e)}{\sigma_{st}}, \quad (7)$$

где σ_{st} - число кратчайших путей из s в t , $\sigma_{st}(e)$ - число таких путей, проходящих через e .

Алгоритм работает следующим образом: (1) для всех рёбер вычисляется $C_B(e)$; (2) удаляется ребро с максимальным C_B ; (3) пересчитываются C_B для оставшихся рёбер; (4) шаги повторяются, пока остаются рёбра. На каждом шаге фиксируется текущее разбиение графа на связные компоненты, и среди всех таких разбиений выбирается то, что максимизирует модулярность

Q.

Идея метода: мосты, соединяющие разные сообщества, лежат на пути от любой вершины одного сообщества к любой вершине другого, поэтому имеют непропорционально большую промежуточность. Алгоритм Брандеса вычисляет C_B всех рёбер за $O(nm)$, и таких подсчётов нужно $O(m)$, что даёт общую сложность $O(nm^2)$. На графах с $n > 1000$ метод практически неприменим, но на малых графах (Karate, Dolphins) даёт качественные разбиения.

2.3.5 Алгоритм Walktrap [10]. Иерархический алгоритм, использующий близость вершин в смысле случайных блужданий.

Определяется матрица переходов $P = D^{-1}A$. После t шагов вероятность P_{ij}^t перехода из i в j характеризует «доступность» j из i . Если i и j принадлежат одному сообществу, их распределения P_i^t и P_j^t должны быть близки. Расстояние между вершинами:

$$r_{ij} = \sqrt{\sum_{k=1}^n \frac{(P_{ik}^t - P_{jk}^t)^2}{\deg(k)}}. \quad (8)$$

Деление на $\deg(k)$ обеспечивает корректное взвешивание (вершины с большой степенью «приходятся» на любое блуждание чаще). На основе расстояний r_{ij} выполняется иерархическая агломеративная кластеризация по методу Уорда: на каждом шаге объединяются два сообщества с наименьшим приростом суммы внутренних квадратов расстояний. Оптимальное число сообществ выбирается по максимуму модулярности дендрограммы. Стандартное значение $t = 4$ - более короткие блуждания не успевают «исследовать» структуру, более длинные размывают границы.

Сводное сравнение. Пять алгоритмов отличаются прежде всего тем, что они оптимизируют: Лувен и Лейден- модулярность, Label Propagation- консенсус соседей (без явного функционала), Гирван-Ньюман- модулярность через удаление мостов, Walktrap- расстояние между распределениями случайных блужданий. Этим определяется их поведение на практике: алгоритмы модулярности страдают от предела разрешения [7] (замечание 2.1); Label Propagation коллапсирует на плотных графах; Walktrap, не привязанный к модулярности, устойчивее на больших графах с большим числом сообществ.

2.4 Метрики качества кластеризации

Оценить «правильность» разбиения, найденного алгоритмом, можно только при наличии истинного разбиения σ^* (получаемого, например, из социометрических наблюдений). Пусть $\hat{\sigma}$ - разбиение, предсказанное алгоритмом. Все метрики ниже измеряют близость $\hat{\sigma}$ к σ^* и нечувствительны к перестановке номеров кластеров.

2.4.1 NMI- нормализованное согласие разбиений. Измеряет, насколько одно разбиение даёт информацию о другом, $NMI \in [0, 1]$. Значение 1 достигается при полном совпадении $\hat{\sigma}$ и σ^* с точностью до перестановки меток; 0 - при полной независимости разбиений (например, при случайном). Принято считать, что $NMI > 0.7$ - сильное согласие, $0.4 - 0.7$ - умеренное, < 0.3 - слабое.

Недостаток: NMI смещена в сторону разбиений с большим числом кластеров. Если предсказание разбивает каждую вершину в отдельный кластер, NMI может оказаться завышенной.

2.4.2 AMI- скорректированный аналог NMI. То же согласие разбиений, что и NMI, но с поправкой на математическое ожидание метрики при случайном разбиении. AMI устраняет смещение NMI: случайное разбиение даёт $AMI \approx 0$ независимо от числа кластеров. По этой причине AMI рекомендуется при сравнении алгоритмов, выдающих разное число сообществ.

2.4.3 ARI- скорректированный индекс Рэнда. Считает долю пар вершин, согласованно сгруппированных (вместе или раздельно) в обоих разбиениях. Пусть $N_{ab} = |\hat{\sigma}^{-1}(a) \cap \sigma^{*-1}(b)|$ - размер пересечения предсказанного кластера a и истинного b , $N_{a\cdot} = \sum_b N_{ab}$, $N_{\cdot b} = \sum_a N_{ab}$. Введём

$$t_1 = \sum_a C_{N_{a\cdot}}^2, \quad t_2 = \sum_b C_{N_{\cdot b}}^2, \quad t_3 = \frac{t_1 t_2}{C_n^2}.$$

Тогда

$$ARI(\hat{\sigma}, \sigma^*) = \frac{\sum_{ab} C_{N_{ab}}^2 - t_3}{\frac{1}{2}(t_1 + t_2) - t_3} \in [-1, 1]. \quad (9)$$

$ARI = 1$ при полном совпадении, ≈ 0 при случайном разбиении, может быть отрицательным при систематическом несогласии. ARI строже NMI : согласовать пары вершин сложнее, чем согласовать метки кластеров.

2.4.4 Точность с лучшей перестановкой меток (best-permutation accuracy).

Применима, когда $\hat{k} = k^*$ - число кластеров совпадает. Алгоритм может присваивать кластерам произвольные номера; метрика учитывает это, перебирая все перестановки π номеров:

$$Acc = \max_{\pi \in S_k} \frac{1}{n} \sum_{v \in V} \mathbf{1}[\pi(\hat{\sigma}(v)) = \sigma^*(v)]. \quad (10)$$

Прямой перебор перестановок имеет сложность $O(k!)$, что недопустимо при $k > 10$. Задача переформулируется как задача о назначениях в двудольном графе и решается венгерским алгоритмом за $O(k^3)$.

2.4.5 Модулярность предсказанного разбиения. В отличие от метрик выше, модулярность $Q(\hat{\sigma})$ (определение 2.8) не требует истинного разбиения и оценивает «внутреннее качество» предсказания: насколько плотность рёбер внутри найденных сообществ превышает ожидаемую в случайной модели. Это особенно ценно, когда σ^* недоступно: можно сравнивать алгоритмы между собой по $Q(\hat{\sigma})$, не имея разметки. Однако высокое Q ещё не гарантирует соответствие σ^* - из-за предела разрешения алгоритм может найти разбиение с $Q > Q(\sigma^*)$, отличающееся от истинного.

Сводное сравнение метрик. NMI и AMI - информационные, ARI - комбинаторная, Acc - ориентирована на согласование меток, Q - внутренняя. На практике для надёжного вывода об алгоритме принято смотреть на все одновременно: согласованно высокие значения NMI , ARI и Q - сильный аргумент в пользу того, что разбиение содержательное.

2.5 Метрики центральности

Для выявления лидеров мнений вычисляются пять метрик:

$$C_D(v) = \deg(v)/(n-1) \quad (\text{степенная}), \quad (11)$$

$$C_B(v) = \sum_{s \neq v \neq t} \sigma_{st}(v)/\sigma_{st} \quad (\text{промежуточная}), \quad (12)$$

$$C_C(v) = (n-1)/\sum_{u \neq v} d(v, u) \quad (\text{близости}), \quad (13)$$

$$Ax = \lambda_1 x, \quad x > 0 \quad (\text{собственного вектора}), \quad (14)$$

$$\pi = \pi M, \quad M_{ij} = \alpha \frac{A_{ij}}{\deg(i)} + \frac{1-\alpha}{n} \quad (\text{PageRank}). \quad (15)$$

Определение 2.10 (композитный ранг). Пусть $r_m(v)$ - ранг вершины по метрике m . Композитным рангом называется

$$R(v) = \frac{1}{5} \sum_m r_m(v). \quad (16)$$

Вершины с наименьшим $R(v)$ считаются лидерами мнений.

2.6 Графовые нейронные сети

Определение 2.11 (GCN, [15]). Слой свёртки:

$$H^{(\ell+1)} = \sigma(\hat{A} H^{(\ell)} W^{(\ell)}), \quad \hat{A} = \tilde{D}^{-1/2}(A + I) \tilde{D}^{-1/2}. \quad (17)$$

Определение 2.12 (GraphSAGE, [16]). Слой с раздельным обучением вершины и соседей:

$$h_v^{(\ell+1)} = \sigma(W_{\text{self}}^{(\ell)} h_v^{(\ell)} + W_{\text{neigh}}^{(\ell)} \cdot \text{AGG}(\{h_u^{(\ell)} : u \in N(v)\})). \quad (18)$$

Функция потерь- кросс-энтропия по обучающему множеству:

$$L(\theta) = -\frac{1}{|V_{\text{train}}|} \sum_{v \in V_{\text{train}}} \sum_c Y_{vc} \log Z_{vc}. \quad (19)$$

Оптимизация Adam [18]:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) \nabla L, \quad v_t = \beta_2 v_{t-1} + (1 - \beta_2) \nabla L^2, \quad \theta_t = \theta_{t-1} - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \varepsilon}. \quad (20)$$

Множество вершин делится стратифицированно на V_{train} (60 %), V_{val} (20 %) и V_{test} (20 %). Применяется ранняя остановка по точности на валидации с $\text{patience} = 50$. Обученная модель сохраняется в чекпоинт- это обеспечивает воспроизводимость и устраняет переобучение между запусками.

3 ПРАКТИЧЕСКИЙ МАТЕРИАЛ

3.1 Программная реализация и используемые датасеты

Реализация выполнена на языке Python 3.12 с использованием библиотек `igraph` (классические алгоритмы и центральности), `leidenalg` (Louvain, Leiden), `PyTorch` (GCN, GraphSAGE), `scikit-learn` (метрики), `matplotlib` (графики). Все эксперименты запускаются единой командой `python main.py`; параметры (датасеты, шаги, гиперпараметры) задаются в файле `config.toml`.

Для эмпирического сравнения использованы три классических малых датасета [3, 6] и три крупных датасета из репозитория Stanford SNAP [19]-таблица 1.

Датасет	n	m	k	Источник
karate	34	78	2	Zachary [3]
dolphins	62	159	2	Lusseau et al. 2003
football	115	613	12	Girvan & Newman [6]
email-Eu-core	986	16 064	42	SNAP [19]
facebook-ego-1684	793	14 816	18	SNAP [19]
dblp-top500	582	2 680	42	SNAP [19]

Таблица 1 Используемые датасеты

3.2 Структурный анализ графов

Для каждого датасета вычислены структурные характеристики (таблица 2): плотность ρ , глобальный коэффициент кластеризации C , средняя длина пути $\bar{\ell}$, ассортативность по степени r_{deg} .

Граф	ρ	C	$\bar{\ell}$	r_{deg}
karate	0.139	0.256	2.41	-0.476
dolphins	0.084	0.309	3.36	-0.044
football	0.094	0.407	2.51	0.162
email-Eu-core	0.033	0.267	2.59	-0.026
facebook-ego-1684	0.047	0.354	1.95	-0.067
dblp-top500	0.016	0.863	9.67	0.803

Таблица 2 Структурные характеристики

Интерпретация параметров. Высокий коэффициент кластеризации C

во всех реальных датасетах (от 0.256 до 0.863) свидетельствует о наличии плотных сообществ- что и есть содержательная цель работы. Сильная отрицательная ассортативность Karate Club ($r_{deg} = -0.476$) указывает на иерархическую структуру: «хабы»- тренер и президент- связаны преимущественно с периферийными вершинами. Сильная положительная ассортативность DBLP ($r_{deg} = 0.803$)- признак того, что соавторы крупных исследовательских групп тесно связаны между собой, образуя плотные клики-конференции. На рисунке 1 показано распределение степеней Karate Club- характерное тяжёлохвостное распределение, типичное для социальных сетей.




Рисунок 1 Распределение степеней в карате-клубе (в логарифмических координатах)

3.3 Бенчмарк классических алгоритмов выделения сообществ

Запущены восемь алгоритмов (Louvain, Louvain классический, Leiden, Label Propagation, Girvan-Newman, Fast Greedy, Walktrap) на всех шести датасетах с усреднением по трём прогонам на малых графах. Результаты для трёх характерных датасетов приведены в таблицах 3, 4, 5.

Наглядное сравнение алгоритмов по NMI на всех датасетах представлено на рисунке 2.

Интерпретация результатов. Алгоритмы оптимизации модулярности (Louvain, Leiden) систематически переразбивают карате-клуб ($\hat{k} = 4$ при $k^* = 2$) и недоразбивают email-Eu-core ($\hat{k} = 7$ при $k^* = 42$). Это прямое проявление предел разрешения [7]. На плотном email-Eu-core с 42 классами Label Propagation коллапсирует в единственную метку ($NMI = 0$), что согласуется

Алгоритм	NMI	ARI	Q_{pred}	$\hat{k}$
Louvain	0.59	0.46	0.420	4
Leiden	0.59	0.46	0.420	4
Label Propagation	0.73	0.77	0.360	2
Girvan-Newman	0.49	0.39	0.401	5
Fast Greedy	0.56	0.57	0.381	3
Walktrap	0.49	0.32	0.353	5

Таблица 3 Karate Club ($k^* = 2$)

Алгоритм	NMI	ARI	Q_{pred}	$\hat{k}$
Louvain	0.85	0.70	0.597	9
Leiden	0.85	0.70	0.597	9
Label Propagation	0.90	0.82	0.600	10
Walktrap	0.89	0.82	0.603	10

Таблица 4 Football ($k^* = 12$)

с известным ограничением алгоритма [8]. Ни один алгоритм не доминирует во всех условиях: на Karate Club лучший- Label Propagation; на Football- Walktrap; на email-Eu-core- Walktrap.

Рисунок 3 визуализирует разбиение карате-клуба алгоритмом Leiden в сравнении с истинным разбиением.

3.4 Обучение графовых нейронных сетей

GCN и GraphSAGE обучались в полу-управляемом режиме на стратифицированном разбиении 60/20/20. Гиперпараметры: `hidden_dim = 64`, `lr = 0.01`, `weight_decay = 5 \cdot 10^{-4}`, `dropout = 0.5`, до 500 эпох, ранняя остановка по `val_acc` с `patience = 50`. Обученные модели сохранялись в каталог `models/`, что позволяет повторно получать те же предсказания без переобучения и обеспечивает воспроизводимость метрик.

Интерпретация результатов. Близость точности на тестовом множестве к точности на валидации (разность ≤ 0.03 для GCN, до 0.17 для GraphSAGE на email-Eu-core) свидетельствует об отсутствии переобучения. На самом сложном датасете (email-Eu-core, 42 класса) GraphSAGE даёт $\text{NMI} = 0.90$ против 0.57 у лучшего классического метода (Walktrap)- относительный прирост 58 %. На малых датасетах GCN и GraphSAGE дают сопоставимый результат:

Алгоритм	NMI	ARI	Q_{pred}	$\hat{k}$
Louvain	0.57	0.29	0.417	7
Leiden	0.57	0.29	0.417	7
Label Propagation	0.00	0.00	0.000	1
Walktrap	0.57	0.19	0.347	110

Таблица 5 email-Eu-core ($k^* = 42$)




Рисунок 2 Сравнение алгоритмов выделения сообществ по NMI

при малом n обе модели сходятся к близкому решению.

3.5 Выявление лидеров мнений

Для каждого датасета вычислены пять метрик центральности и композитный ранг $R(v)$ (определение 2.10). Результаты для карате-клуба приведены в таблице 7.

Интерпретация. Композитный ранг автоматически выделяет двух исторических лидеров карате-клуба- тренера Mr. Hi (узел 0) и президента John A. (узел 33), вокруг которых произошёл реальный раскол в 1972 году. Это прямое эмпирическое подтверждение применимости теоретико-графового подхода к социометрии. На email-Eu-core лидером является узел 160 с $\text{deg} = 345$ и $R(v) = 1.00$ - сотрудник с максимальным числом email-контактов и наибольшим PageRank.




Рисунок 3 Разбиение карате-клуба: слева- Leiden ($\hat{k} = 4$), справа- истинное разбиение ($k^* = 2$). Размер узла пропорционален PageRank

Датасет	Модель	Train	Val	Test	NMI	ARI
karate	GCN	1.00	1.00	0.88	0.84	0.88
karate	GraphSAGE	1.00	1.00	0.88	0.84	0.88
dolphins	GCN	1.00	1.00	1.00	1.00	1.00
dolphins	GraphSAGE	1.00	1.00	1.00	1.00	1.00
football	GCN	0.88	0.87	0.87	0.89	0.83
football	GraphSAGE	0.90	0.87	0.87	0.90	0.82
email-Eu-core	GCN	0.84	0.83	0.78	0.82	0.75
email-Eu-core	GraphSAGE	0.98	0.81	0.81	0.90	0.87
facebook-ego	GCN	0.90	0.91	0.86	0.82	0.85
facebook-ego	GraphSAGE	0.98	0.90	0.84	0.88	0.91
dblp-top500	GCN	1.00	1.00	0.98	0.99	0.99
dblp-top500	GraphSAGE	1.00	1.00	0.99	1.00	1.00

Таблица 6 Результаты обучения GCN и GraphSAGE на разбиении 60/20/20

3.6 Выявление изолированных групп

В качестве предсказанного разбиения для расчёта conductance $\varphi(S)$ использовался результат Leiden [17]. Применены три эвристики: несвязные компоненты, сообщества с малым conductance, периферия по k -core.

Интерпретация. На карате-клубе обнаружены три низко-conductance сообщества ($\varphi \leq 0.143$) и одна периферийная вершина (coreness = 1). На сети футбола найдена клика-конференция размера 9 с внутренней плотностью 1.000 и conductance 0.148- конференция, играющая преимущественно внутри себя. На DBLP обнаружено сообщество размера 26 с conductance 0.002 и плотностью 0.926- типичная малая исследовательская группа, почти полно-

Узел	deg	C_B	PR	$R(v)$
0 (Mr. Hi, тренер)	16	231.07	0.097	1.50
33 (John A., президент)	17	160.55	0.101	1.75
32	12	76.69	0.072	3.50
2	10	75.85	0.057	3.50
31	6	73.01	0.037	5.25

Таблица 7 Лидеры мнений в карате-клубе [3]

стью изолированная от остального графа: conductance близок к нулю означает, что почти все рёбра группы- внутренние.

ЗАКЛЮЧЕНИЕ

В курсовом проекте решены все поставленные во введении задачи.

1. Актуальность темы, история вопроса и обзор литературы. Прослежено развитие методов анализа социальных графов от социограмм Морено [1] (1934) к эре модулярности [6, 9, 17] (2002-2019) и к графовым нейронным сетям [15, 16] (с 2017). Систематизированы три современных семейства методов: модулярность, случайные блуждания, нейронные сети.

2. Математическая модель. Дано строгое определение графа, моделей случайных графов ($G(n, p)$, BA, WS), модулярности Ньюмана, метрик качества (NMI, AMI, ARI, accuracy) и центральности (degree, betweenness, closeness, eigenvector, PageRank), архитектур GCN и GraphSAGE.

3. Программная реализация. Реализован модуль бенчмарка с единым интерфейсом $f: G \rightarrow \mathbb{Z}^n$. GNN обучаются с корректным разделением вершин на обучающую, валидационную и тестовую выборки и сохранением модели в чекпоинт, что обеспечивает воспроизводимость результатов.

4. Эмпирическое сравнение. На шести датасетах разного размера установлено: алгоритмы модулярности страдают от предел разрешения [7], Label Propagation [8] коллапсирует на плотных графах с большим числом классов, Walktrap [10] наиболее устойчивы среди классики. При наличии частичной разметки GraphSAGE [16] даёт $NMI = 0.90$ на email-Eu-core против 0.57 у лучшего классического метода- относительный прирост 58 %.

5. Содержательные результаты. Композитный ранг центральностей автоматически выделяет двух исторических лидеров карате-клуба, что подтверждает применимость подхода. Эвристики conductance и k -core обнаруживают изолированные структуры с ясной социальной интерпретацией: клики-конференции в Football, исследовательские группы в DBLP.

Рекомендации. Без разметки- использовать Leiden или Walktrap; при наличии разметки- GraphSAGE. Корректное использование обучающая/валидационная выборки и чекпоинтов обязательно для воспроизводимости.

Дальнейшие направления: архитектуры GAT, GIN; временные графы; перекрывающиеся сообщества; применение к задачам обнаружения координированной дезинформации.

СПИСОК ЛИТЕРАТУРЫ

- [1] Moreno, J. L. Who Shall Survive? - Washington : Nervous and Mental Disease Publishing, 1934. - 440 p.
- [2] Erdős, P., Rényi, A. On Random Graphs I // Publicationes Mathematicae. - 1959. - Vol. 6. - P. 290-297.
- [3] Zachary, W. W. An information flow model for conflict and fission in small groups // Journal of Anthropological Research. - 1977. - Vol. 33, No. 4. - P. 452-473.
- [4] Watts, D. J., Strogatz, S. H. Collective dynamics of small-world networks // Nature. - 1998. - Vol. 393. - P. 440-442.
- [5] Barabási, A.-L., Albert, R. Emergence of scaling in random networks // Science. - 1999. - Vol. 286, No. 5439. - P. 509-512.
- [6] Girvan, M., Newman, M. E. J. Community structure in social and biological networks // Proceedings of the National Academy of Sciences. - 2002. - Vol. 99, No. 12. - P. 7821-7826.
- [7] Fortunato, S., Barthélemy, M. Resolution limit in community detection // Proceedings of the National Academy of Sciences. - 2007. - Vol. 104, No. 1. - P. 36-41.
- [8] Raghavan, U. N., Albert, R., Kumara, S. Near linear time algorithm to detect community structures in large-scale networks // Physical Review E. - 2007. - Vol. 76, No. 3. - P. 036106.
- [9] Blondel, V. D., Guillaume, J.-L., Lambiotte, R., Lefebvre, E. Fast unfolding of communities in large networks // Journal of Statistical Mechanics: Theory and Experiment. - 2008. - No. 10. - P10008.
- [10] Pons, P., Latapy, M. Computing communities in large networks using random walks // Journal of Graph Algorithms and Applications. - 2006. - Vol. 10, No. 2. - P. 191-218.

- [11] Brandes, U., Delling, D., Gaertler, M. et al. On modularity clustering // IEEE Transactions on Knowledge and Data Engineering. - 2008. - Vol. 20, No. 2. - P. 172-188.
- [12] Newman, M. E. J. Networks: An Introduction. - Oxford : Oxford University Press, 2010. - 720 p.
- [13] Diestel, R. Graph Theory. - 5th ed. - Heidelberg : Springer, 2017. - 428 p.
- [14] Defferrard, M., Bresson, X., Vandergheynst, P. Convolutional neural networks on graphs with fast localized spectral filtering // Advances in Neural Information Processing Systems. - 2016. - P. 3844-3852.
- [15] Kipf, T. N., Welling, M. Semi-supervised classification with graph convolutional networks // Proceedings of ICLR. - 2017. - arXiv:1609.02907.
- [16] Hamilton, W. L., Ying, R., Leskovec, J. Inductive representation learning on large graphs // Advances in Neural Information Processing Systems. - 2017. - P. 1024-1034.
- [17] Traag, V. A., Waltman, L., van Eck, N. J. From Louvain to Leiden: guaranteeing well-connected communities // Scientific Reports. - 2019. - Vol. 9. - Article 5233.
- [18] Kingma, D. P., Ba, J. Adam: A method for stochastic optimization // Proceedings of ICLR. - 2015. - arXiv:1412.6980.
- [19] Leskovec, J., Krevl, A. SNAP Datasets : Stanford Large Network Dataset Collection [Электронный ресурс]. - Режим доступа: <https://snap.stanford.edu/data>. - Дата доступа: 21.05.2026.